



Data Science в складских процессах, или чего не хватает кандидатам



Анна
Дубенюк





✉ Анна Дубенюк

ozon{tech



Образование

- ✓ Магистратура: прикладная математика и информатика, ФКН НИУ ВШЭ
- ✓ Бакалавриат: прикладная математика и информатика, Финансовый университет
- ✓ Выпускница физмата 192 школы

Где сейчас

- ✓ Ozon Tech, тимлид RnD, оптимизация и моделирование складских процессов, руковожу математиками-разработчиками
- ✓ Преподаю машинное обучение в ВШЭ, в аттестационных комиссиях, спикер CodeFest, автор канала «Всё предельно»

Предыдущий опыт в IT

- ✓ Ситимобил: алгоритмы назначения заказов
- ✓ Яндекс.Еда: алгоритмы доставки продуктов
- ✓ Московский кредитный банк: ML в рознице
- ✓ Сбер: HR-моделирование

План на сегодня

Роли в IT

Кто работает в IT? Какие бывают аналитики?
Команды и роли

Работа, задачи

Реальные задачи и инструменты,
математическое моделирование на складах

Навыки и рост

Уровни должностей, карьерный рост, матрица
компетенций, карты навыков


Поиск работы

Этапы отбора кандидатов, виды стажировок,
чего часто не хватает кандидатам

Вопросы

+контакты

Что? Где? Когда?
Канал про data science




Создание IT-продукта

01 Discovery

Исследование, проверка гипотез.
Решаем что, для кого и как делаем.


02 Delivery

Реализация: разработка, тестирование,
Запуск проекта. Создание результата.




Роли в Data Science

Discovery – исследования и аналитика



Delivery – реализация решений в production



В каждой компании своя специфика, управленческая структура.

Роль – это не должность.

Даже в одной компании должности могут означать разное.

Роли меняются.

Роли в разработке IT-продукта

Продакт-менеджер

Ведёт продукт от идеи до реализации. Формирует стратегию и видение. Развивает продукт. Часто управляет командой бизнес-аналитиков

Проджект-менеджер

Управляет проектами, соединяет разные части бизнеса компании в небольшие кросс-команды для реализации проекта, например, IT, финансы и операции

Бизнес-аналитик

Строит схемы процессов, собирает требования от заказчиков и описывает их в соответствии с возможностями и приоритетами проекта

Тимлид/техлид разработки

Продумывает архитектуру, распределяет задачи между разработчиками и контролирует их выполнение. Иногда может быть отдельный архитектор

Разработчик

Пишет код, думает о стабильности системы, согласовывает контракты, поддерживает сервисы (иногда SRE)

Тестировщик

Проверяет правильность кода как с точки зрения бизнеса, так и технически, оценивает стабильность сервисов при нагрузках

Если продукт сложный, нужны аналитики

Бизнес-аналитик

Выявляет потребности бизнеса, улучшает процессы, строит BPMN-схемы

Продуктовый аналитик

Следит за рынком, ищет точки роста, проверяет гипотезы, генерит метрики

Data Scientist

Проводит исследования, строит модели для принятия решений (data + бизнес), иногда есть ML-инженеры

Data Engineer

Работает с базами данных, отвечает за хранилище, потоки данных, помогает DS

Системный аналитик

Мыслит на уровне сервисов, продумывает архитектуру, ставит задачи разработке

UX-аналитик

Проектирует интерфейсы, продумывает интуитивно-понятную логику

Если продукт очень сложный, то создают отдельные команды математиков

Research & Development — исследования и разработка инновационных продуктов, технологий и процессов с **высокой степенью неопределенности**.

Строим различные виды моделей для повышения производительности процессов и прогнозирования эффекта от внедрений. Прототипирование, исследования, data-driven-подход для принятия решений.

Помогаем разработке не делать лишних действий, находим точки роста, придумываем алгоритмы, снижаем неопределённость

Верхнеуровневый процесс работы RnD

- **Оценка масштабов** и локализация проблем
- **Разработка прототипа** с учётом бизнес-ограничений
- **Оценка эффекта от прототипа**, сравнение архитектур, показ
- **Сопровождение** в момент передачи в разработку

На любом из этапов может выясниться, что надо остановиться — и это хорошо, не будут потрачены ресурсы на разработку неэффективного решения



Физика склада



Задания для сотрудников склада

- 📍 Действия сотрудников логируются.
- ✅ Оцифрованные товары и их местоположение – это огромные массивы данных.

Математические модели и исследования позволяют сократить количество действий, уменьшить пробеги сотрудников и распределить нагрузку на них.

ТСД (терминал сбора данных)

Портативный компьютер со сканером, с которым сотрудник работает на складе.



Оптимизационная модель

Общая постановка оптимизационной задачи:

$f(x) \rightarrow \min(\max), f(\cdot)$ – целевая функция

$g_i(x) \leq 0, i = 1, \dots, m$ – ограничения вида неравенств

$h_j(x) = 0, j = 1, \dots, k$ – ограничения вида равенств

x – вектор размера n , X – множество значений x



Примеры методов оптимизаций:

- Симплекс-метод
- Метод внутренней точки
- Градиентный спуск
- Метод разделяющей гиперплоскости

Вид задачи	Суть
Безусловная оптимизация	Ограничений нет, $X = R^n$
LP (linear programming)	Все функции линейны
MILP (mixed integer linear programming)	Задачи линейного программирования, где только часть переменных целочисленные
CP (constraint programming)	Поиск допустимого решения из большого числа кандидатов, фокус на ограничениях
QP (quadratic programming)	Целевая функция квадратична, несколько переменных, ограничения линейны

В проде применяют солверы. Каждый солвер решает задачи определенного вида.

Примеры солверов:

OR-Tools от Google: MPSolver, Glop, CP-SAT

SCIP: LP, MIP, NLP, MINLP, CNS, DNLP, and QCP

CUOPT от NVIDIA: MIP, MINLP

GUROBI: LP, MIP, QCP, MIQCP

Базовый пример работы с солвером (CP-SAT)

Максимизируйте $2x + 2y + 3z$
при следующих ограничениях

$$x + \frac{7}{2}y + \frac{3}{2}z \leq 25$$

$$3x - 5y + 7z \leq 45$$

$$5x + 2y - 6z \leq 37$$

$$x, y, z \geq 0$$

x, y, z integers

```
1 from ortools.sat.python import cp_model
2
3 model = cp_model.CpModel()
4
5 var_upper_bound = max(50, 45, 37)
6 x = model.new_int_var(0, var_upper_bound, "x")
7 y = model.new_int_var(0, var_upper_bound, "y")
8 z = model.new_int_var(0, var_upper_bound, "z")
9
10 model.add(2 * x + 7 * y + 3 * z <= 50)
11 model.add(3 * x - 5 * y + 7 * z <= 45)
12 model.add(5 * x + 2 * y - 6 * z <= 37)
13
14 model.maximize(2 * x + 2 * y + 3 * z)
15
16 solver = cp_model.CpSolver()
17 status = solver.solve(model)
18
19 if status == cp_model.OPTIMAL or status == cp_model.FEASIBLE:
20     print(f"Maximum of objective function: {solver.objective_value}\n")
21     print(f"x = {solver.value(x)}")
22     print(f"y = {solver.value(y)}")
23     print(f"z = {solver.value(z)}")
24 else:
25     print("No solution found.")
```

Инструменты и примеры задач

Основные инструменты



Data-driven-подход

Проверка гипотез для принятия управленческих решений — какую тарификацию поставить, какую технику выбрать, как эффективнее делать.

Оптимизационные модели

Алгоритмы для прода — какие товары и в какой момент собирать, куда размещать товары, как назначать задания на исполнителей.

ML-модели, имитационное моделирование

Machine learning — прогноз длительности задания, его производительности.
Дискретно-событийное моделирование: «что будет, если», потоки, СМО.

Где подробнее узнать про задачи RnD в Ozon Tech

Статья на Хабре про
математику на складах




Доклад на CodeFest
про задачу батчинга



Вебинар на лектории ФКН
с задачей про сортеры




Уровни должностей (грейды)




Уровень должности не регламентирован и зависит от сложности проектов компании, от предыдущего опыта работы и навыков. Для правильного определения уровня должности используется матрица компетенций.

Доход состоит из оклада и премий. В больших компаниях есть процесс review.



Hard skills и soft skills



01

Матрица компетенций постепенно меняется

Конкретные скиллы отличаются от команды к команде. Появляются новые технологии, необходимо постоянно развиваться.

02

Чем выше уровень должности, тем важнее софт-скиллы

Старший специалист (сеньор) решает проблему, младший специалист (джуниор) решает задачу. Старшие специалисты / руководители больше работают с командой, чем пишут код.

03

Важно уметь донести результаты

Даже если вы сделали гениальное исследование, но его никто не понял, ваш business value — нулевой.

Пример компетенций из матрицы

Data Science Analytics

1. Алгоритмы дискретной оптимизации
2. Алгоритмы машинного обучения
3. Имитационное моделирование
4. Статистические методы анализа данных
5. Проверка статистических гипотез
6. Дизайн и оценка экспериментов (A/B, switchback)
7. Наглядный результат: документация, визуализация и презентация
8. Проведение оценки качества исследований, сравнение методологий

Data Science Engineering

1. Программирование на Python, использование релевантных для задачи библиотек
2. SQL — получение данных из разных источников, сохранение слепков, выбор оптимальной структуры
3. Управление данными (OLAP, ETL), проектирование схем
4. Алгоритмы и структуры данных
5. Проведение оценки качества кода, отладка
6. Инфраструктура и архитектура сервисов, масштабирование
7. Работа с большими данными в Hadoop: Spark, Hive, Kafka

Project Management

1. Качественное исполнение и ответственность за результат
2. Декомпозиция задач, прозрачность — понятен статус выполнения, проблемы и сроки
3. Коммуникации и менеджмент стейкхолдеров

People Management

1. Наём, удержание, увольнение
2. Онбординг, настройка процессов
3. Управление мотивацией и ростом

Data Science Innovation

1. Развитие RnD-экспертизы внутри команды, компании (кросс-опыление)
2. Развитие и популяризация RnD вне Ozon (статьи, конференции и т. д.)

Ожидания владения скиллами коррелируют с уровнем должности

Владение: знаю о навыке / применяю / понимаю / могу выбирать лучшее / могу научить лучшим практикам


Карта навыков ML-разработчиков

* на основе данных поиска Яндекса и тегам на Stack Overflow

● Обработка естественного языка ● Компьютерное зрение ● Прочее глубокое обучение ● Прочее машинное обучение

Размер шрифта навыка отражает число запросов с ним, а близость расположения навыков показывает совместную частотность в контексте.

Есть возможность находить навыки-альтернативы и проследивать динамику интереса с 2010 года




Подбор кандидатов

Воронка подбора:

- Сбор откликов на вакансию
- Разбор резюме рекрутером
- HR-скрининг
- Тех. собеседования
(обычно — тех. скрининг и тех. интервью)
- Финальное собеседование
(по сути — знакомство с рук-лем и командой)
- Презентация оффера
- Выход кандидата на работу
онбординг, прохождение испытательного срока

Стажировки двух типов:

- ✓ Волновые программы стажировок (Ozon Camp...)
- ✓ Точечные вакансии на стажировку (Ozon Tech, Ozon Fintech)



Чего часто не хватает кандидатам

Прикладные навыки

- ✓ **Понимание, а не заучивание.** Фундамент алгоритмов на 1х курсах — линейная алгебра, теория вероятности, статистика и анализ.
- ✓ **Математический кругозор.** Инструмент зависит от задачи. Нужен не только ML, но и понимание дискретной оптимизации с практикой на солверах.
- ✓ **Готовность к реальным данным.** В реальности данные не идеальны, нужно уметь с этим работать.
- ✓ **Современные инструменты.** Облачные платформы (AWS, Google Cloud, Azure), CI/CD, контейнеризация (Docker, Kubernetes), мониторинг моделей в проде.

Мета-навыки

- ✓ **Ориентация на практическую применимость.** Как решения могут быть внедрены в реальный бизнес, как влияют на конечного пользователя, CJM.
- ✓ **Умение читать научные статьи,** проведение экспериментов, готовность к неопределенности.
- ✓ **Адаптивность,** нетворкинг, командная работа (управление проектом, делегирование, принятие решений).
- ✓ **Погружение в экономику и этику.** Стоимость вычислений и вопросы этики — предвзятость моделей, прозрачность.

Идея

Междисциплинарные проекты на реальных данных помогают студентам «смоделировать работу»: совместные проекты с биологами, логистами и т.д.



Вопросы

telegram | @andu192

вакансии | job.ozon.ru



Канал с инфографикой вокруг
data science