

Обзор методов безопасного федеративного обучения

Гонгапшев Астемир
Университет “Сириус”
NoML

Сокращения

- Federated Learning (FL) – федеративное обучение
- Homomorphic Encryption (HE) – гомоморфное шифрование
- Differential Privacy (DP) – дифференциальная приватность
- Horizontal Federated Learning (HFL) – горизонтальное федеративное обучение
- Secure Multi-Party Computation (SMPC) – безопасное многопартийное вычисление
- Vertical Federated Learning (VFL) – вертикальное федеративное обучение
- Trusted Execution Environments (TEE) – доверенная среда выполнения

План

1

Общие сведения
про федеративное
обучение


2

HE, SMPC, TEE, DP


3

Комбинация
FL + (HE, DP,
SMPC, TEE)

FL - это..



Вертикальное FL



Горизонтальное FL



Математическая постановка задачи FL

$$\min_{w \in \mathbb{R}^n} \left\{ f(w) = \frac{1}{N} \sum_{k=1}^N f_k(w) \right\},$$

где N — количество устройств, $f: \mathbb{R}^n \rightarrow \mathbb{R}$ — глобальная целевая функция, $f_k: \mathbb{R}^n \rightarrow \mathbb{R}$ — локальная целевая функция на устройстве k .

Пусть случайная величина ξ определена на вероятностном пространстве $(\Omega, \mathcal{F}, \mathbb{P})$, с некоторой σ -алгеброй $\mathcal{F}$ и вероятностной мерой $\mathbb{P}$. Локальная целевая функция имеет вид:

$$f_k(w) = \mathbb{E}_{\xi \sim \mathcal{D}_k} [\mathcal{L}(w, \xi)],$$

где $\mathcal{L}(w, \xi)$ — функция потерь, вычисляемая на выборке ξ из локального датасета $\mathcal{D}_k$.

Communication-Efficient Learning of Deep Networks from Decentralized Data

H. Brendan McMahan, Eider Moore, Daniel Ramage, Seth Hampson, Blaise Agüera y Arcas

FedAvg

Require: T, η, E, N .

Сервер: инициализировать w_0 и отправить его всем клиентам.

Клиенты: $\mathcal{B} \leftarrow$ (разделить $\mathcal{P}_k$ на батчи размера B)

for $t = 0, \dots, T - 1$ **do**

for $i = 1, \dots, E$ **do**

for $b \in \mathcal{B}$ **do**

$$w_{t,i+1}^k = w_{t,i} - \eta \nabla \mathcal{L}(w_{t,i}^k; b)$$

end for

end for

 Отправить серверу $w_{t,E}^k$

Сервер: агрегировать обновлённые параметры:

$$w_{t+1} = \sum_{k=1}^N p_k w_{t,E}^k$$

Сервер: Отправить w_{t+1} всем клиентам.

end for

Require: T, η, E, N, μ .

Сервер: инициализировать w_0 и отправить его всем клиентам.

Клиенты: $\mathcal{B} \leftarrow$ (разделить $\mathcal{P}_k$ на батчи размера B)

for $t = 0, \dots, T - 1$ **do**

for $i = 1, \dots, E$ **do**

for $b \in \mathcal{B}$ **do**

$$w_{t,i+1}^k \approx \arg \min_w \left\{ h_k(w_{t,i}, w_t) := f_k(w_{t,i}) + \frac{\mu}{2} \|w_{t,i} - w_t\|^2 \right\}$$

end for

end for

 Отправить серверу $w_{t,E}^k$

Сервер: агрегировать обновлённые параметры:

$$w_{t+1} = \sum_{k=1}^N p_k w_{t,E}^k$$

Сервер: Отправить w_{t+1} всем клиентам.

end for

Направление	Алгоритмы
Агрегация моделей	FedAvg, FedProx, FedOPT
Ускорение сходимости	Scaffold, FEDHQ, FedProx
Снижение гетерогенности	FedDist, FedProx, FedOPT
Конфиденциальность	RFA, LEGATO, HeteroSAg
Снижение затрат связи и вычислений	FedMA, LAQ, SAFA
Качество обучения	FAIR, FedPSO

Reviewing Federated Learning Aggregation Algorithms; Strategies, Contributions, Limitations and Future Perspectives

Проблема безопасности в FL

Параметры k -го устройства при
передачи находятся в открытом
виде

iDLG: Improved Deep Leakage from
Gradients
Bo Zhao, Konda Reddy Mopuri,
Hakan Bilen

Evaluating Gradient Inversion Attacks
and Defenses in Federated Learning
Yangsibo Huang, Samyak Gupta, Zhao
Song, Kai Li, Sanjeev Arora





Figure 8: Reconstruction results of MNIST digits under different defenses with the strongest attack and batch size 1.



(e) Original (f) BN_{exact}

Подходы к обеспечению безопасности в FL




Схема шифрования $\Pi = (\text{KeyGen}, \text{Enc}, \text{Dec})$ с множеством открытых текстов $\mathbb{O}$ и множеством шифротекстов $\mathbb{M}$ называется *гомоморфной относительно бинарной операции* $\oplus_{\mathbb{O}} : \mathbb{O} \times \mathbb{O} \rightarrow \mathbb{O}$, если существует (эффективно вычислимая) бинарная операция $\otimes_{\mathbb{M}} : \mathbb{M} \times \mathbb{M} \rightarrow \mathbb{M}$ такая, что для любых $m_1, m_2 \in \mathbb{O}$ и любых ключей (pk, sk) , сгенерированных алгоритмом KeyGen, выполняется

$$\text{Dec}_{sk}(\text{Enc}_{pk}(m_1) \otimes_{\mathbb{M}} \text{Enc}_{pk}(m_2)) = m_1 \oplus_{\mathbb{O}} m_2.$$

$$\mathbf{w}_{t+1} = \frac{1}{N} \sum_{k=1}^N \text{Enc}(\mathbf{w}_t^{(k)})$$

Схема	Гомоморфная операция	
	Сложение	Умножение
RSA (Rivest et al. 1978b)		✓
GM (Goldwasser и Micali 1982)	✓	
El-Gamal (ElGamal 1985)		✓
Benaloh (Benaloh 1994)	✓	
NS (Naccache и Stern 1998)	✓	
OU (Okamoto и Uchiyama 1998)		✓
Paillier (Paillier 1999)	✓	
DJ (Damgård и Jurik 2001)	✓	
KTX (Kawachi et al. 2007)		✓
Galbraith (Galbraith 2002)		✓

Microsoft SEAL



PALISADE (Lattice Crypto)



HElib (IBM)



TenSEAL




Пусть $M : \mathcal{D} \rightarrow \mathcal{R}$ — рандомизированный алгоритм с областью входных данных $\mathcal{D}$ и множеством выходов $\mathcal{R}$. Алгоритм M называется (ε, δ) -дифференциально *приватным*, если для любых двух соседних наборов данных $D_1, D_2 \in \mathcal{D}$, отличающихся ровно одним элементом, и для любого измеримого подмножества $S \subseteq \mathcal{R}$ выполняется неравенство

$$\Pr[M(D_1) \in S] \leq e^\varepsilon \Pr[M(D_2) \in S] + \delta,$$


где вероятности берутся по внутренней случайности алгоритма M , $\varepsilon \geq 0$ задаёт уровень приватности, а $\delta \geq 0$ — допустимую вероятность нарушения этого ограничения.

$$\mathbf{w}_t = \frac{1}{N} \sum_{k=1}^N \mathbf{w}_t^{(k)}, \quad \mathbf{g}_{t+1} = \mathbf{w}_t + \mathcal{N}(0, \sigma^2 I)$$


ROC AUC/Test



Loss/Test




Accuracy/Test




train 3


ROC AUC/Val



Loss/Val




Accuracy/Val




TEE — доверенная аппаратная среда, в которой код выполняется изолированно от остальной системы, а данные надёжно защищены даже от привилегированных атакующих (ядро, гипервизор, администратор).

TEE	Разработчик
<u>Intel SGX</u>	Intel
<u>AMD SEV / SEV-SNP</u>	AMD
<u>ArmTrustZone</u>	Arm
<u>Keystone Enclave</u>	Keystone Project / RISC-V сообщество




S MPC



SMPC

Фреймворк	Краткий функционал
<u>Sharemind</u>	Коммерческая платформа MPC от Cybernetica, основана на secret sharing, использовалась в реальных гос. и промышленных проектах.
<u>MP-SPDZ</u>	Открытая реализация множества протоколов (SPDZ и др.), активно используется в исследованиях и прототипах безопасных вычислений.
<u>SCALE-MAMBA</u>	Фреймворк для MPC с поддержкой протоколов на secret sharing и богатым набором примитивов для вычислений.
<u>ABY / ABY3</u>	Библиотеки, комбинирующие разные представления секретов (arithmetic / Boolean / Yao) для эффективных MPC, часто применяются для ML.



● TEE ■ PUF ● QC ■ CBE ● NC ■ SI

HW Dependency

■ SI — Swarm Intelligence


■ CBE — Chaos-Based Encryption

● TEE — Trusted Execution Environment

■ PUF — Physical Unclonable Function


● QC — Quantum Computing

● NC — Neuromorphic Computing



Maturity

Practicality



Emerging Paradigms for Securing Federated Learning Systems

Литература

■ Deep Learning with Differential Privacy
Martín Abadi, Andy Chu, Ian Goodfellow, H.
Brendan McMahan, Ilya Mironov, Kunal Talwar,
Li Zhang

■ Differentially Private
Federated Learning: A Client
Level Perspective

■ {BatchCrypt}: Efficient homomorphic
encryption for {Cross-Silo} federated learning
C Zhang, S Li, J Xia, W Wang, F Yan, Y Liu



■ Korkmaz A., Rao P. A Selective
Homomorphic Encryption Approach
for Faster Privacy- Preserving
Federated Learning // arXiv preprint
arXiv:2501.12911. — 2025.

■ A Hybrid Approach to Privacy-Preserving Federated
Learning
Stacey Truex, Nathalie Baracaldo, Ali Anwar, Thomas
Steinke, Heiko Ludwig, Rui Zhang, Yi Zhou


■ Protecting data from all parties: Combining
FHE and DP in federated learning
AG Sébert, R Sirdey, O Stan, C Gouy-Pailler

■ Federated Optimization in Heterogeneous
Networks
Авторы: Tian Li, Anit Kumar Sahu, Manzil
Zaheer, Maziar Sanjabi, Ameet Talwalkar, Virginia
Smith

■ Communication-Efficient Learning of Deep Networks
from Decentralized Data
H. Brendan McMahan, Eider Moore, Daniel Ramage,
Seth Hampson, Blaise Agüera y Arcas



Спасибо!



@ASTEMIR_GONGAPSEV