



МСистемы

Вероятностные графовые модели и Байесовские сети


Манякин Илья, PhD
mbayes.ru

NoML, 2025.12.24







1. История
 - 1.1 Вычислительная техника и интерфейсные технологии
 - 1.2 Искусственный интеллект, абстракция, algorithmic complexity
2. Математическая основа
 - 2.1 Случайность, Вероятности, Распределения
 - 2.2 Теорема Байеса
3. Вероятностные графовые модели
 - 3.1 Типы ВГМ
 - 3.2 Байесовские сети и базовые примеры
 - 3.3 Применения
4. Future prospects




1912-1954




1903-1957




50 Years of Microprocessor Trend Data




Original data up to the year 2010 collected and plotted by M. Horowitz, F. Labonte, O. Shacham, K. Olukotun, L. Hammond, and C. Batten
New plot and data collected for 2010-2021 by K. Rupp






Транзистор, 1947



IC, 1958




IC, 2015




Катодные трубки, 1900е


LCD



Жидкокристаллический экран, 1970е



Светодиоды, ~1962




Компьютерная мышь, 1968




Телефон, ~1870

Artificial Intelligence




[1] Advancements in microprocessor architecture for ubiquitous AI—An overview on history, evolution, and upcoming challenges in AI implementation, Micromachines, 2021

Abstractions & Algorithmic Complexity



Layers of Abstraction

Термин: “software-hardware co-design”



- **P**: polynomial algorithm complexity class
- **NP**: non-deterministic polynomial
- **NP-complete**: problem is in NP & polynomial time algorithm exists to reduce any problem in NP to the problem
- **NP-hard**: a problem is NP-hard if all problems in NP are polynomial time reducible to it, even though it may not be in NP itself



Условная вероятность

$$P(B|A) = \frac{P(B, A)}{P(A)} \quad \text{при } P(A) > 0$$

Независимость

$$A \perp B \implies P(A, B) = P(A)P(B)$$




$E[X]$, $\text{Var}[X]$ + Монте-Карло оценки

$$\mathbb{E}[f(X)] = \int f(x) \cdot p(x) dx \approx \frac{1}{N} \sum_{i=1}^N f(x_i) \quad x_i \sim p(x)$$

Распределения

- continuous/discrete
- univariate/multivariate


...ИХ ОЧЕНЬ МНОГО






Совместное распределение

$$P(B,A) = P(A,B)$$



$$P(B|A)P(A) = P(B,A) = P(A,B) = P(A|B)P(B)$$



Теорема Байеса

$$\underset{\text{posterior}}{P(B|A)} = \frac{\underset{\text{likelihood}}{P(A|B)} \underset{\text{prior}}{P(B)}}{\underset{\text{marginal likelihood/ evidence}}{P(A)}}$$



Пьер-Симон Лаплас
(1749-1827)*



Томас Байес
(1702-1761)

Теорема Байеса - 2



Bayes

posterior = likelihood $\times$ prior / evidence

Log posterior

$\log(\text{posterior}) = \log(\text{likelihood}) + \log(\text{prior}) - \log(\text{evidence})$

Maximum a posteriori (MAP)

$\log(\text{posterior}) \approx \log(\text{likelihood}) + \log(\text{prior}) - \log(\text{evidence})$


Maximum likelihood (MLE)


$\log(\text{posterior}) \approx \log(\text{likelihood}) + \log(\text{prior}) - \log(\text{evidence})$

Пример


$$p(x|\mu, \sigma) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x - \mu)^2}{2\sigma^2}\right)$$

$$\log[p(x|\mu, \sigma)] = -\frac{1}{2}\log[2\pi\sigma^2] - \frac{(x - \mu)^2}{2\sigma^2}$$






Байесовская сеть
направленная



Марковская сеть
ненаправленная



Фактор граф

- [4] Probabilistic graphical models: principles and techniques, Koller & Friedman, 2009
- [5] Artificial Intelligence a modern approach, 3rd ed., Russell & Novig, 1995
- [6] Turbo decoding as an instance of Pearl's "belief propagation" algorithm, MacKay, 1998




Совместное распределение $\leftrightarrow$ Байесовская сеть = DAG + Набор условных распределений


- **Направленный ациклический граф (Directed Acyclic Graph, DAG)**
 - $G = (V, E)$
 - Имеет как минимум 1 топологический порядок (*topological ordering*) узлов
- **Условные распределения**
 - Для каждой случайной переменной X_i требуется определить: $P(X_i \mid \text{parents}(X_i))$
- Каждый узел $v_i \in V \leftrightarrow$ случайная переменная X_i
 - **Родители:** $\text{parents}(X_i) = \{X_j \mid v_j \rightarrow v_i \in E\}$
 - **Дети:** $\text{children}(X_i) = \{X_j \mid v_i \rightarrow v_j \in E\}$

$$P(X_1, \dots, X_m) = \prod_{i=1}^m P(X_i \mid \text{parents}(X_i))$$

Математическая форма $\longleftrightarrow$ Разные варианты представления модели



Графовая форма






- **Различные типы**


- Статические / динамические
- Дискретные (discrete) / Непрерывные (continuous) / Гибридные (hybrid) / Гауссовские (gaussian/CLG)

- **Байесовская сеть = структура данных**

- Inference алгоритмы могут быть разными
 - Различные типы запросов
 - Различные типы узлов и графов
 - Требования к скорости вычислений




Фото




Видео=Фото(t)




Статическая




Динамическая




Дискретные



Непрерывные



Гибридные



Потенциальные вопросы: Сколько узлов, сколько связей, как представить условные вероятности, как обучить модель, как сделать fit-predict

Базовый Пример 1 – Категориальные узлы



узел: A id: n1 тип: категориальный


Таблица условной вероятности

a1	-	a2	-	a3	-	+
0.25		0.3		0.45		$\Sigma=1$

узел: B id: n2 тип: категориальный

Таблица условной вероятности

A	b1	-	b2	-	+
a1	0.4		0.6		$\Sigma=1$
a2	0.25		0.75		$\Sigma=1$
a3	0.8		0.2		$\Sigma=1$



Базовый Пример 1 – Категориальные узлы 2



узел: A id: n1 тип: категориальный

Таблица условной вероятности



a1	-	a2	-	a3	-	+
0.25		0.3		0.45		$\Sigma=1$

узел: B id: n2 тип: категориальный

Таблица условной вероятности

A	b1	-	b2	-	+
a1	0.4		0.6		$\Sigma=1$
a2	0.25		0.75		$\Sigma=1$
a3	0.8		0.2		$\Sigma=1$

prior marginal $P(A) \rightarrow$ легко: $P(A)$



Prior marginal query (x2) $P(Q) = \sum_M P(Q \cup M)$

Q: query node set, M: marginalization node set

prior marginal $P(B) = \sum_A P(B|A)P(A)$

Базовый Пример 1 – Категориальные узлы 3



узел: A id: n1 тип: категориальный

Таблица условной вероятности

a1	-	a2	-	a3	+
0.25		0.3		0.45	$\Sigma=1$



узел: B id: n2 тип: категориальный

Таблица условной вероятности

A	b1	-	b2	+
a1	0.4		0.6	$\Sigma=1$
a2	0.25		0.75	$\Sigma=1$
a3	0.8		0.2	$\Sigma=1$

Значение: b2

posterior marginal: $P(A | B=b2)$



Posterior marginal $P(Q | E = e) = \sum_M P(Q \cup M | E = e)$

Q : query node set, M : marginalization node set, E : evidence node set

Базовый Пример 2 – Непрерывные узлы




$$p(n_1 | \mu = 0, \sigma_1 = 1) \sim \text{Normal}(\mu = 0, \sigma = 1)$$

узел: n1	id: n1	тип: непрерывный		
Таблица условной вероятности				
loc	scale	distribution	lower_bound	upper_bound
0	1	normal		

$$p(n_2 | n_1, \sigma_2) \sim \text{Normal}(\mu = 3 \cdot n_1, \sigma_2 = 1)$$

узел: n2	id: n2	тип: непрерывный		
Таблица условной вероятности				
loc	scale	distribution	lower_bound	upper_bound
3*n1	1	normal		



Базовый Пример 2 – Непрерывные узлы



узел: n1 id: n1 тип: непрерывный

Таблица условной вероятности



loc	scale	distribution	lower_bound	upper_bound
0	1	normal		

узел: n2 id: n2 тип: непрерывный

Таблица условной вероятности

loc	scale	distribution	lower_bound	upper_bound
3*n1	1	normal		

Значение: 1.781



Базовый Пример 3 – Mixture



узел: n1 id: n1 тип: категориальный

Таблица условной вероятности


comp_1	-	comp_2	-	comp_3	-	+
0.25		0.6		0.15		$\Sigma=1$

узел: n2 id: n2 тип: непрерывный


Таблица условной вероятности

	n1	loc	scale	distribution	lower_bound	upper_bound
comp_1	-3	1.5	normal	▼		
comp_2	1.5	0.9	normal	▼		
comp_3	4	1.1	normal	▼		

marginals



joint



Вопрос

Предположим, существует диагностический тест для вируса.

Ложноположительное соотношение (false-positive rate, т.е. пропорция положительных результатов теста у людей, не имеющих вируса) составляет **1 на 1000**. Допустим вы прошли тестирование **тест был положительным** (т.е. показал наличие вируса).

Какова вероятность того, что у вас **действительно есть вирус**?

Варианты ответа

1. 99.9%
2. 99%
3. 1%
4. 0.01%
5. 'Не достаточно информации'
6. 'Не знаю'

Правильно ответили всего 16% (~1 из 6)



viral
prevalence

узел: has_virus id: n1 тип: категориальный

Таблица условной вероятности

yes	-	no	-	+
inf	inf	$\Sigma=\text{NaN}$		


узел: test_positive id: n2 тип: категориальный

Таблица условной вероятности

has_virus	yes	-	no	-	+
yes	inf	inf	$\Sigma=\text{NaN}$		
no	0.001	0.999	$\Sigma=1$		

Ошибка 1го рода


Ошибка 2го рода



Наивный байесовский классификатор




- Простая 2х уровневая структура
- **Non-causal** model
- Evidence – можно вводит в любые узлы
 - В тех узлах в которых нет evidence получаем posterior estimates
- Калибровка быстрая (пример: MLE) для каждого узла



Extensions:

- Tree augmented Naive Bayes (TAN)
- Hidden Naive Bayes Classifiers



[9] https://scikit-learn.org/stable/modules/naive_bayes.html

[10] Weka, <https://ml.cms.waikato.ac.nz/index.html>

Регрессия








$\text{gradient} \sim \text{Normal}(0, 3)$

$\text{intercept} \sim \text{Normal}(0, 3)$

$\sigma \sim \text{InverseGamma}(a = 15, b = 3)$

$y_i \sim \text{Normal}(\mu = \text{gradient} \cdot x_i + \text{intercept}, \sigma)$




В примере узлы x_i = deterministic

[11] Linear regression with errors in both variables, Minka, 1999

[12] Bayesian linear regression, Minka, 1998


“Linear regression with errors in both variables is a common modeling problem with a 100-year literature, yet we have still not achieved the widespread use of a complete and correct solution”



Независимость и условная независимость




Common cause




$$n_1 \perp n_3 \mid n_2$$

Linear chain




$$n_1 \perp n_3 \mid n_2$$

Common effect/Collider



$$n_1 \not\perp n_3 \mid n_2$$

Descendant



$$n_1 \not\perp n_3 \mid \{n_2, n_4\}$$

d-separation: графовый тест который позволяет вычислить условные независимости между случайными переменными модели на основе **структуры графа (связей и их направления)**.


definition(d-separation): Let X, Y, Z be disjoint sets of nodes in a DAG G . Sets X and Y are d-separated by Z $dsep(X, Y \mid Z)$ iff every path between a node in X and a node in Y is blocked by Z iff at least one valve on the path is closed given Z .

Collider – интуиция





$Normal(\mu = 0, \sigma = 1)$

$Normal(\mu = 0, \sigma = 1)$




$Z \sim Normal(\mu = \boxed{X + Y}, \sigma = 1)$



Uncorrelated (apriori)

Z=2

E[n1]	5.27601e-3	σ[n1]	1.00101e+0
E[n2]	-1.40401e-3	σ[n2]	9.89619e-1
Cov[n1, n2]	-5.23928e-3	ρ[n1, n2]	-5.28888e-3
MI[n1, n2]	6.88000e-2		



Correlated (aposteriori)



E[n1]	6.75852e-1	σ[n1]	8.20857e-1
E[n2]	6.52634e-1	σ[n2]	8.10681e-1
Cov[n1, n2]	-3.32743e-1	ρ[n1, n2]	-5.00025e-1
MI[n1, n2]	2.05343e-1		

Collider – интуиция 2




$Normal(\mu = 0, \sigma = 1)$

$Normal(\mu = 0, \sigma = 1)$




$Z \sim Normal(\mu = X^2 + Y^2, \sigma = 1)$



Uncorrelated (apriori)

$Z=2$



Correlated (aposteriori)

Прикладные модели - Сенсоры



Класс задачи: *Switching Linear Dynamical Systems (SLDS)*




Рис. 1. Примеры сбоев в работе сенсоров. А – Сбой с переходом (Hard-over Fault), В - Нестабильные колебания (Erratic Fault), С – Дрейф (drift fault).




Рис. 2. Истинная температура и показания измерений трёх температурных сенсоров с разными уровнями шума, $\sigma_1=0.7$ °C, $\sigma_2=1.2$ °C, $\sigma_3=1.8$ °C




Рис. 5. Ошибка типа Сбой с переходом (Hard-over Fault) в работе первого сенсора. Цветные точки – измерения каждого сенсора, чёрная линия – истинное значение температуры.




Рис. 8. Ошибка типа Нестабильные колебания (Erratic Fault) в работе первого сенсора. Цветные точки – измерения каждого сенсора




Рис. 11. Ошибка типа Дрейф (Drift fault) в работе первого сенсора. Цветные точки – измерения каждого сенсора, чёрная линия – истинное значение температуры.



Таблица условной вероятности

loc	scale	distribution
n7	1.0	normal ▾













Таблица условной вероятности



state1(t)	distribution	loc	scale	lower_
ok	normal ▾	n8	0.7	
fault	normal ▾	0	40	

Таблица условной вероятности

n3	ok	-	fault	-	+
ok	0.99	0.01	$\Sigma=1$		
fault	0.01	0.99	$\Sigma=1$		

Прикладные модели – Сенсоры 3










Figure 4: Dilution study for tetramethylrhodamine (TAMRA), showing the average spectrum at each of 21 concentrations from 0.13 to 24.7 nM.



(b) TAMRA.


Figure 6: Posterior distributions for the peaks and baselines of rhodamine B and tetramethylrhodamine (TAMRA). Minor peaks at 815 and 960 cm^{-1} have been missed by the model for TAMRA.




(a) TAMRA at 0.13 nM.



R-2R ladder




Bandpass filter uncertainty



```
* Effecting a Monte Carlo calculation in ngspice
V1 N001 0 AC 1 DC 0
R1 N002 N001 141
```

```
* define distributions for random numbers:
* unif: uniform distribution, deviation relativ to nominal value
* aunif: uniform distribution, deviation absolut
* gauss: Gaussian distribution, deviation relativ to nominal value
* agauss: Gaussian distribution, deviation absolut
* limit: if unif. distributed value >=0 then add +avar to nom, else -avar
define unif(nom, rvar) (nom + (nom*rvar) * sunif(0))
define aunif(nom, avar) (nom + avar * sunif(0))
define gauss(nom, rvar, sig) (nom + (nom*rvar)/sig * sgauss(0))
define agauss(nom, avar, sig) (nom + avar/sig * sgauss(0))
* define limit(nom, avar) (nom + ((sgauss(0) ge 0) ? avar : -avar))
define limit(nom, avar) (nom + ((sgauss(0) >= 0) ? avar : -avar))
```

- Цифровой двойник устройства
- Анализ надежности
- Model-based fault diagnostics
- Root causes analysis (RCA)



[15] https://github.com/imr/ngspice/blob/master/examples/Monte_Carlo/MonteCarlo.sp

[16] PSpice Simulation Tutorial: How to Modify a Monte Carlo Histogram with PSpice



Риск: влияние неопределенности на цели
(risk: effect of uncertainty on objectives)

Серия ISO 31000

B.2 Identification of risks

Checklists/classifications/taxonomies
Failure models & effects analysis (FMEA,FMECA)
Hazard and operability (HAZOP)

Scenario Analysis

B.3 Determining sources, causes and drivers of risk

Cindynic approach
Ishikawa analysis

B.4 Analyse existing controls

Bow tie analysis

Hazard analysis (HACCP)
Layers of protection (LOPA)

B.5 Understanding impact and likelihood

Bayesian analysis, Bayesian networks

Business impact analysis

Cause-consequence analysis

Event-tree & Fault tree analysis

Human reliability analysis

Markov Analysis

Monte Carlo simulation

B.6 Analysing dependencies & interactions

Causal mapping

Cross impact analysis

B.7 Providing measures of risk

Toxicological risk assessment

Value at risk (VaR)

Conditional value at risk (Cvar)

B.8 Evaluating the significance of risk

ALARP & SFAIRP
Frequency diagrams
Pareto charts

Reliability centered maintenance (RCM)

Risk indices

B.9 Selecting between options



Cost/benefit analysis
Decision tree analysis
Game theory

Multi-criteria analysis

B.10 Recording and reporting

Risk registers
Risk matrix


S-curves







Модель Крамера-Лундберга

$$S_{i+1} = S_i - (1 - \alpha)r\Delta t_i + c\Delta t_i - \sum_{j=1}^{N_i} \alpha X_{ij}$$



Параметр	Описание	Распределение
S_i	Капитал компании в $[t_{i-1}, t_i]$	$S_0 = constant$
c	Premium rate	$c = (1 + \theta)\lambda\mathbb{E}[X]$
N_i	Количество страховых случаев (claims)	$N_i \sim Poisson(\lambda)$
λ	Интенсивность страховых случаев	$\lambda_i \sim Normal(\lambda_{i-1}, \sigma_\lambda)$
X_{ij}	Размер страховых выплат по j -му страховому случаю, во время i	$X_{ij} \sim Lognormal(\mu_X, \sigma_X)$
θ	Insurance premium loading factor	$\theta > 0$
m	операционные расходы страховой	$m > 0$
α	Retention rate, уровень пропорционального перестрахования	$\alpha \in [0, 1]$
r	Размер премии по перестрахованию	$r = (1 + \eta)\lambda\mathbb{E}[X]$
η	Reinsurance premium loading factor	$0 < \eta < \theta$






Рис. 12: Модель устойчивости поставщика




Рис. 6: Модель общей стоимости и параметров, влияющих на нее






Рис. 1: Основной критерий (Primary_criteria) выбора поставщика и факторы, которые на него напрямую влияют - надежность поставок, сервис, качество продукта и стоимость.




NPV (Net Present Value/Чистый дисконтированный доход): показатель для оценки финансовой привлекательности инвестиционного проекта. Представляет собой чистый доход по инвестиционному проекту, который приведен к стоимости на сегодняшний день с использованием механизма дисконтирования.




- Software-hardware co-design
- Compiled inference & probabilistic circuits
 - [18] Probabilistic circuits: A unifying framework for tractable probabilistic models
- Law Zero & Hybrid inference systems
 - [19] Superintelligent Agents Pose Catastrophic Risks: Can Scientist AI Offer a Safer Path?
- Probabilistic numerics (uncertainty aware integration)
 - [20] Probabilistic numerics and uncertainty in computations
- Quantum systems for probabilistic algorithms
 - [21] Experimental investigation of performance differences between coherent Ising machines and a quantum annealer
- Thermodynamic computing (~HW Gibbs sampler?)
 - <https://extropic.ai/writing/thermodynamic-computing-from-zero-to-one>




- **Цель:** Упрощение применения стохастического моделирования и Байесовских методов
- Позволяет пользователю **сфокусироваться на моделировании**, а не реализации алгоритмов
- Разделение **модели** и **кода**
- Моделирование **иерархических** и **взаимосвязанных** структур
- **Прямой** (Монте-Карло) и **Обратный** (Байесовский) анализ




Low Code
редактор
моделей



Библиотеки
графовых
алгоритмов



Библиотеки
обучения моделей
на данных



Вычислительные
движки



МСистемы

Спасибо за внимание!

Манякин Илья, PhD
mbayes.ru

NoML, 2025.12.24

